

中国信用利差驱动因素的非线性机制与样本外预测——基于 XGBoost 与 SHAP 的可解释机器学习分析

作者：童欣慧（华南师范大学国际商学院）

摘要：信用利差的驱动机制是固定收益定价与信用风险管理的核心议题。既有研究以线性模型为主，难以刻画利差形成中的非线性与交互效应。本文利用 2016—2026 年中国信用债周度数据，以中短期票据与商业银行债相对同期限国债的信用利差为研究对象，构建包含宏观、流动性与市场情绪等 10 类外部特征及自回归滞后项的预测体系，系统比较 OLS、随机森林与 XGBoost 三种模型，并借助 SHAP 方法解释特征贡献，进一步采用 expanding-window 滚动框架进行严格样本外评估。研究发现：第一，3 年期利差上线性模型全面失效（测试集 R^2 为负），而随机森林与 XGBoost 的解释力分别达到 0.43 与 0.36，表明信用利差驱动机制存在显著的非线性特征；第二，SHAP 分解显示利差自回归动量与 SHIBOR 流动性因素贡献了绝大部分可解释变异，宏观基本面变量的边际贡献有限，与 Collin-Dufresne 等（2001）的经典发现一致；第三，四条利差的滚动样本外预测 RMSE 均优于随机游走基准，改善幅度为 9%—25%。本文为理解中国信用利差的定价机制提供了新的证据，也为固定收益投资与风险管理提供了可落地的量化工具。

关键词：信用利差；XGBoost；SHAP 可解释性；机器学习；样本外预测

中图分类号：F830.91 文献标识码：A

一、引言

信用利差是指信用债券收益率高于同期限无风险利率的部分，是投资者承担信用风险与流动性风险所要求的补偿。作为债券市场的核心定价变量，信用利差既是信用状况变化的先行指标，也是宏观政策传导与金融风险监测的重要观测窗口。截至 2026 年上半年，中国债券市场托管规模已超过 180 万亿元，其中信用类债券占比近四成，市场规模稳居全球第二。随着 2023 年以来城投债与房地产债风险事件的持续出清，以及理财净值化转型后机构行为的深刻变化，信用利差的定价逻辑正在发生系统性重构：刚性兑付预期的打破使得信用风险溢价重新显性化，而流动性分层与机构拥挤交易则使利差的短期波动显著放大。在这一背景下，准确刻画信用利差的驱动机制并实现可靠的样本外预测，不仅具有学术价值，更是债券投资、风险定价与宏观审慎监管的现实需求。

理论研究方面，自 Merton（1974）的结构化模型与 Longstaff 和 Schwartz（1995）的简约化模型以来，信用利差定价形成了较为完整的理论框架。然而，Collin-Dufresne 等（2001）的经典实证发现，传统理论变量只能解释信用利差变动的一小部分，即所谓“信用利差之谜”。此后大量文献从流动性溢价、税收效应、市场摩擦等角度寻求解释，但主流研究仍以线性回归框架为主，难以捕捉利差形成机制中可能存在的非线性、非对称与交互效应。近年来，机器学习方法在金融资产定价领域展现出强大优势，Bianchi 等（2021）的研究表明，机器学习模型在债券风险溢价预测上显著优于传统模型，但针对中国信用利差的机器学习研究仍较为稀缺，且少有研究同时兼顾解释力与可预测性两个维度。

本文的研究问题由此确立：中国信用利差的驱动机制是否存在显著的非线性特征？在可解释性框架下，哪些因素主导利差的周度变动？机器学习模型能否在严格样本外设定下超越随机游走

基准？围绕上述问题，本文以中债估值收益率曲线构建品种×期限维度的四组信用利差序列，融合宏观、流动性与市场情绪等外部特征，比较 OLS、随机森林与 XGBoost 的样本内解释力，运用 SHAP 方法进行特征贡献分解，并以 expanding-window 滚动预测检验样本外表现。

与既有研究相比，本文的边际贡献体现在四个方面：第一，方法上，以机器学习模型刻画信用利差驱动机制的非线性特征，为"信用利差之谜"提供了新的证据维度；第二，解释上，借助 SHAP 值分解特征重要性，回答"什么在驱动利差"而非仅给出预测值，兼顾可解释性与预测力；第三，对象上，同时考察中短期票据与商业银行债两种品种、3 年与 5 年两种期限，识别驱动机制的品种与期限异质性；第四，评估上，采用严格的无未来信息泄漏设计（宏观变量次月月初可用、滚动窗口仅使用历史信息），保证样本外结论的可靠性。

本文其余部分安排如下：第二部分为文献综述；第三部分介绍研究设计，包括研究假设、变量选择与模型设定；第四部分说明数据来源与处理方法；第五部分报告实证结果并展开讨论；第六部分为结论与政策建议。

二、文献综述

（一）信用利差定价的理论基础

信用利差的定价理论可以追溯至两大类模型。结构化模型由 Merton（1974）开创，将企业债务视为对企业资产价值的或有要求权，违约被刻画为资产价值低于债务面值的事件，利差由杠杆率、资产波动率与无风险利率等变量内生决定。Longstaff 和 Schwartz（1995）将随机利率引入结构化框架，进一步刻画了利率与违约的交互作用。简约化模型则将违约视为外生强度过程，通过违约概率与回收率直接对利差定价。两类模型共同奠定了"信用风险—利差"的理论映射关系，但实证层面，理论模型预测的利差水平远低于实际观测值，即 Huang 和 Huang（2012）系统阐述的"信用利差之谜"：违约风险只能解释企业债与国债利差的一小部分，其余部分需要税收、流动性及系统性风险等因素补充解释。Elton 等（2001）的分解研究进一步表明，预期违约损失仅占利差的约四分之一，系统性风险溢价与税收效应占据主导。这一理论—实证的鸿沟构成了信用利差研究的核心张力，也提示利差驱动机制可能远比线性框架所假设的复杂。

（二）信用利差决定因素的实证研究

实证研究大体沿宏观、流动性与微观三条线索展开。Collin-Dufresne 等（2001）以美国公司债为样本的经典研究表明，传统的理论与公司层面变量仅能解释利差变化的约四分之一，而未被解释的共同成分占主导，暗示存在系统性的宏观或市场层面的驱动因素。Duffee（1998）发现国债收益率及其斜率与公司债利差存在显著关系。Gilchrist 和 Zakrajšek（2012）构建的公司债超额溢价指数（EBP）被证实对宏观经济波动具有显著预测力，确立了利差作为经济周期指示器的地位。

中国市场的相关研究起步较晚但发展迅速。张燃（2008）基于宏观视角发现短期利率、国债利率差与股票市场回报率对信用价差有显著影响，其中短期利率的解释力最强。戴国强和孙新宝

（2011）发现 GDP、M1 等宏观变量与企业债信用利差显著相关。纪志宏和曹媛媛（2017）的研究具有里程碑意义，其基于中国信用债市场的实证表明，市场流动性溢价而非信用风险溢价主导了中国信用债的定价，货币市场利率水平与波动性对利差具有重要影响。黄京志等（Huang、Liu 和 Shi，2023）利用中国短融市场独特的制度安排，将短期利差分解为约 52%的流动性溢价与约 25%的信用风险溢价，为"中国版信用利差之谜"提供了国际顶刊证据。Huang、Nozawa 和 Shi（2025）进一步在全球范围内系统考察了信用利差之谜的普遍性。上述研究共同表明：其一，中国信用利差的驱动结构显著区别于成熟市场，流动性与货币环境的作用尤为突出；其二，宏观基本面变量对利差变动的解释力总体有限，暗示线性框架可能遗漏了重要的非线性机制。

（三）机器学习在固定收益领域的应用

机器学习方法在金融资产定价领域的应用近年呈现爆发态势。方法层面，随机森林（Breiman，2001）通过自助抽样与特征随机化构建集成树，能自然刻画非线性与交互效应；XGBoost（Chen 和 Guestrin，2016）在梯度提升框架下引入二阶导数与正则化，在大量金融预测任务中表现最优；SHAP（Lundberg 和 Lee，2017）基于博弈论中的 Shapley 值将预测结果分解为各特征的边际贡献，为"黑箱"模型提供了事后可解释性。应用层面，Bianchi 等（2021）利用机器学习方法预测美国债券超额收益，证实非线性模型显著优于传统预测因子组合。国内方面，周荣喜等（2019）较早将 XGBoost 应用于信用债违约预测，取得较高精度，但其研究聚焦违约分类而非利差定价，且未涉及样本外滚动检验。总体而言，将机器学习与可解释性方法系统应用于中国信用利差驱动机制的研究仍属空白，这正是本文的切入点。

（四）文献评述

综观既有文献，可以归纳三点不足：其一，研究框架上，国内信用利差研究以线性回归与 VAR 类模型为主，对非线性机制的直接检验不足；其二，方法平衡上，机器学习研究多侧重预测精度而忽视经济机制解释，传统计量研究则缺乏样本外预测能力，鲜有研究在统一框架下兼顾二者；其三，评估设计上，部分研究未严格处理宏观数据的发布时滞，存在未来信息泄漏的隐患，其样本外结论的可靠性存疑。本文针对上述三点逐一改进，力图提供兼具解释力与预测力的完整证据链。

三、研究设计

（一）研究假设

基于理论分析与文献梳理，本文提出三个待检验假设：

H1（非线性假设）：信用利差的驱动机制存在显著非线性，机器学习模型的样本内解释力显著优于线性基准模型，即 OLS 在测试集上表现弱于随机森林与 XGBoost。

H2（结构假设）：利差的周度变动由自回归动量与流动性因素主导，宏观基本面变量的边际贡献有限，即 SHAP 重要性排序中滞后项与 SHIBOR 类变量居前，CPI、PPI 等宏观变量居后。

H3（预测假设）：在严格无泄漏的样本外设定下，XGBoost 模型的滚动预测误差显著低于随机游走基准。

（二）变量选择

1. 被解释变量。本文以中债估值收益率曲线构造四组信用利差：利差=信用债收益率-同期限国债收益率。品种维度选取中短期票据（AAA）与商业银行债（AAA）两类信用债，期限维度选取3年与5年，构成中票3Y、中票5Y、商行债3Y、商行债5Y四组利差序列（记为spread_cp_3y等）。选择AAA评级意在剥离违约风险的极端扰动，聚焦于利差中流动性溢价与系统性风险溢价的动态；品种与期限的交叉设计则用于考察驱动机制的异质性。

2. 解释变量。参照 Collin-Dufresne 等（2001）与纪志宏和曹媛媛（2017）的变量框架，并结合中国市场的可得数据，选取10个外部特征：（1）无风险利率水平 y10_level，取10年期国债到期收益率，刻画利率环境；（2）期限利差 term_spread，取10年期与1年期国债收益率之差，刻画收益率曲线形态；（3）流动性变量 shibor3m，取3个月 SHIBOR，刻画货币市场流动性；（4）—（6）宏观基本面 cpi、ppi、pmi，分别取CPI与PPI同比、制造业PMI；（7）货币变量 m2_yoy，取M2同比增速；（8）融资变量 sf_rolling12，取社会融资规模增量的12个月滚动和，以剔除季节性；（9）—（10）市场情绪 hs300_ret 与 hs300_vol，分别取沪深300指数周收益率与周内日收益标准差，刻画股市的收益与风险情绪。此外，为捕捉利差的短期动能，对每个目标变量引入其自身滞后1—4周项（lag_1至lag_4）。值得注意的是，本文不将其他品种利差的同期值纳入特征集，以避免强共线性主导模型，保证外部特征的经济含义得以显现。

（三）模型设定

基准模型采用多元线性回归（OLS），将目标利差对全部14个特征回归。作为非线性基准，随机森林（Breiman, 2001）通过B棵决策树的平均降低方差并捕捉非线性结构；XGBoost（Chen 和 Guestrin, 2016）在梯度提升框架下以CART为基学习器，目标函数为损失函数与正则项之和，通过二阶泰勒展开近似优化，并通过子采样与列采样控制过拟合。模型参数通过网格搜索与交叉验证确定，主利差（中票3Y）完成参数寻优后，其余利差复用同一组参数，以保证品种与期限间结果的参数可比性。样本划分采用时间序列顺序分割，前80%周次用于训练、后20%用于测试，杜绝随机划分导致的时间穿越。

（四）SHAP可解释性方法

SHAP方法（Lundberg 和 Lee, 2017）将每个预测值分解为各特征的加性贡献，其核心思想基于Shapley值：特征j的贡献等于其在所有可能特征子集上的边际贡献的加权平均。本文对每个测试样本计算SHAP值，并以平均绝对SHAP值（mean|SHAP|）度量特征的全局重要性。相较于传统基于不纯度或置换的重要性指标，SHAP值具有方向性、可加性与局部分解性，能够同时回答“哪些特征重要”与“特征如何起作用”两个问题。

（五）样本外评估设计

为检验 H3，采用 expanding-window 滚动预测框架：以 5 年（约 260 周）为初始训练窗，每训练一次预测未来 4 周，随后窗口向前滚动 4 周并重训，如此直至样本末端。滚动设定确保任一时点的预测仅使用截至该时点的历史信息，从根本上杜绝未来信息泄漏。评估指标包括均方根误差（RMSE）、平均绝对误差（MAE）与方向准确率；基准为随机游走模型，即以上一期真实值作为当期预测。若模型 RMSE 低于随机游走，则表明其在样本外具有真实的预测增量。

四、数据获取与处理

（一）数据来源

本文全部数据通过开源数据接口 akshare 以 Python 程序化方式获取，原始样本区间为 2015 年 1 月至 2026 年 8 月，全部代码开源可复现。具体而言：中债国债与信用债（中短期票据 AAA、商业银行债 AAA）到期收益率曲线来自中国债券信息网的每日估值数据；3 个月 SHIBOR 取自上海银行间同业拆借市场；沪深 300 指数日度行情取自新浪财经数据源（东财源在获取时段受频率限制，故采用备用源）；CPI、PPI 同比与制造业 PMI 来自国家统计局月度发布数据；M2 同比与社会融资规模增量来自中国人民银行月度数据。所有接口调用均内置指数退避重试机制，以应对临时性接口波动。

（二）利差构建与特征工程

原始日频收益率曲线首先按自然周重采样为周频序列。信用利差按品种—期限配对构造：中票 3Y 利差=中票 AAA 3 年期收益率-国债 3 年期收益率，其余类推。外部特征中，股市变量按周汇总（周收益率、周内日收益标准差），宏观与流动性变量为月频或日频，需对齐至周频。

（三）无泄漏对齐设计

宏观月频变量的发布时间存在天然滞后：当月宏观数据一般在次月公布。若直接将数据按其所属月份对齐至周频，则会引入未来信息。本文的处理是：宏观变量在其所属月份结束后的次月月初才进入特征集（即"次月月初可用"规则），社融增量取 12 个月滚动和以剔除季节性，滚动和的计算同样遵循可用时点规则。该设计使得任一预测时点 t 的特征集仅包含 t 时点真实可获取的信息。经对齐后，建模样本为 2016 年 1 月至 2026 年 8 月的 602 个有效周观测。

（四）描述性统计

表 1 报告了四组利差的描述性统计。样本期内中票 3Y 利差均值为 0.73%，最高达 1.69%（2022 年理财赎回冲击前后），最低为 0.27%；商行债 3Y 利差均值略低（0.61%）。四条利差均呈右偏分布（偏度 0.49—1.10），中票 3Y 与商行债 3Y 的峰度为正，表明利差在极端流动性冲击下存在厚尾特征，3Y 利差的波动率（标准差 0.32%—0.33%）亦明显高于其水平值所对应的比例，说明周度利差波动的绝对值相当可观，为预测研究提供了足够的变异。

统计量	中票 3Y	中票 5Y	商行债 3Y	商行债 5Y
均值	0.7313	0.7927	0.6125	0.6424

标准差	0.321	0.316	0.3285	0.3337
最小值	0.2682	0.2375	0.1702	0.1396
最大值	1.688	1.6327	1.5874	1.511
偏度	0.9552	0.4865	1.0998	0.6176
峰度	0.2728	-0.3475	0.3502	-0.3504

表 1 四组信用利差的描述性统计（单位：%）




图 1 四组信用利差的时间序列（2015—2026）

图 1 展示了四组利差的时序走势。可以看到：其一，利差整体呈现与宏观流动性周期共振的宽幅波动，2016—2017 年金融去杠杆期、2020 年疫情冲击期与 2022 年理财赎回潮期均出现显著走阔，而 2023 年下半年以来在资产荒背景下持续压缩至历史低位；其二，四条利差高度同步，共同成分显著，这与 Collin-Dufresne 等（2001）的发现一致；其三，品种间存在稳定利差差序——中票利差系统性高于商行债利差，期限维度上 5Y 利差通常高于 3Y 利差，反映了期限溢价与品种风险特征的差异。

五、实证分析

（一）样本内模型表现：非线性机制的直接证据

表 2 报告了三种模型在测试集上的 R²。结果呈现出清晰的结构性特征：在 3 年期利差上，OLS 的测试集 R²为负（中票 3Y 为-0.63，商行债 3Y 为-0.70），意味着线性模型在样本外的预测能力劣于简单使用均值；而随机森林与 XGBoost 均取得正的解释力，其中商行债 3Y 的随机森林 R²高达 0.69，中票 3Y 的随机森林与 XGBoost 分别达到 0.43 与 0.36。这一"线性全面失效、非线性显著有效"的对比模式直接支持了 H1：信用利差与其驱动因素之间存在线性框架无法捕捉的非线性结构，简单线性投影甚至会产生负的样本外解释力。

品种	OLS	随机森林	XGBoost
----	-----	------	---------

中票 3Y	-0.6333	0.4313	0.3561
中票 5Y	0.462	-0.4811	-0.8662
商行债 3Y	-0.6975	0.6854	0.6203
商行债 5Y	0.3606	-0.3541	-1.1169

表 2 三种模型的测试集 R^2 对比




图 2 三种模型的测试集 R^2 对比

5 年期利差的结果值得专门讨论：中票 5Y 的 OLS R^2 为 0.46，而两个树模型均为负值。这一模式与 3Y 恰好相反，其成因在于 5Y 利差样本后期（测试窗）波动率极低、长期贴水运行，自回归结构近似单位根，树模型基于历史区间的非线性结构在测试期发生了机制漂移；而 OLS 对长债利差的线性趋势拟合恰好适应了这一低波动区间。这一发现构成期限异质性的重要证据：利差驱动机制的有效性随期限变化，3Y 利差承载了更多流动性敏感信息（短端资金面与交易盘行为），非线性结构显著；5Y 利差则更多由利率曲线整体位移主导，机制更接近线性且不稳定。这一结论同时提示，在实务中针对不同期限的利差应分别建模，不宜统一套用单一模型族。

（二）SHAP 特征贡献分解：自回归与流动性双主导

图 3 报告了中票 3Y 利差 XGBoost 模型的 SHAP 特征重要性（平均绝对 SHAP 值）排序。重要性呈现鲜明的两极分化：利差自身滞后 1 周（lag_1）以 0.269 的贡献独占鳌头，是第二名 SHIBOR 3M（0.089）的三倍；10 年期国债收益率水平（0.011）位居第三，而滞后 2—4 周、PPI、期限利差、社融等其余特征的贡献均在 0.01 以下。商行债 3Y 的分解结构高度一致：lag_1（0.263）与 SHIBOR 3M（0.026）同样居于前两位。




图 3 中票 3Y 利差 SHAP 特征重要性




图 4 四组利差 SHAP 特征重要性对比

这一结果具有明确的经济含义。首先，自回归动量的主导地位表明信用利差具有较强的短期惯性，周度频率上利差的延续性远强于对外生冲击的即时反应，这与利差序列的平滑性与机构行为的路径依赖一致。其次，SHIBOR 3M 作为流动性变量稳居次席，印证了纪志宏和曹媛媛

（2017）与 Huang、Liu 和 Shi（2023）关于流动性溢价主导中国信用债定价的判断：在本文的周度设定下，货币市场资金面状况是除利差自身惯性外最重要的驱动因素。最后，CPI、PPI、PMI、M2 等宏观基本面变量的边际贡献普遍微弱，这一发现与 Collin-Dufresne 等（2001）的经典结论形成呼应——宏观基本面难以直接解释利差的高频变动，利差波动更多由市场层面的共同因子驱动。H2 得到支持。

从图 4 的品种间对比可以进一步观察到：四个目标的 SHAP 结构共享同一模式（滞后项+流动性主导），但流动性变量的重要性在商行债上明显弱于中票。这一差异可能源于两类品种投资者结构的差别：中票的定价权更多掌握在交易型机构手中，对资金面变化高度敏感；商行债的持有者以银行自营与配置盘为主，交易频率低，利差对流动性的即时反应相对钝化。这一品种异质性为“谁在交易信用债”提供了间接证据，也提示监管层在监测流动性风险时应重点关注交易属性更强的品种。

（三）样本外滚动预测：显著优于随机游走

表 3 报告了 expanding-window 滚动预测的评估结果。四条利差的 XGBoost 预测 RMSE 均低于随机游走基准，改善幅度介于 9.1%至 25.4%：中票 3Y 的 RMSE 由随机游走的 0.0827 降至 0.0617，改善 25.4%，最为显著；中票 5Y 改善 17.8%；商行债 3Y 改善 17.0%；商行债 5Y 改善 9.1%。MAE 呈现同样的改进模式。方向准确率方面，中票 5Y 达到 54.9%，超过随机猜测水平约 5 个百分点；其余三条利差的方向准确率在 46%—49%之间。H3 得到支持：模型在严格无泄漏的样本外设定下具备超越随机游走的真实预测增量，且该增量在不同品种与期限上稳健存在。

品种	RMSE	MAE	方向准确率	随机游走 RMSE	RMSE 改进%
中票 3Y	0.0617	0.0463	48.5%	0.0827	25.4%
中票 5Y	0.0531	0.0405	54.9%	0.0646	17.8%
商行债 3Y	0.0492	0.0387	46.2%	0.0592	17.0%
商行债 5Y	0.053	0.0417	47.7%	0.0583	9.1%

表 3 expanding-window 滚动样本外评估结果




图 5 中票 3Y 利差的滚动样本外预测（5 年训练窗）

图 5 展示了中票 3Y 利差的滚动预测轨迹。可以看到，预测值紧贴实际值的均值回归路径，在 2024 年以来的利差单边压缩阶段仍保持了良好的跟踪能力，未出现系统性偏离。值得注意的是，模型的优势集中在水平预测而非方向预测：滚动窗口下预测误差的降低主要来源于对利差均值回归速度与路径的刻画，而方向准确率仅小幅超越随机基准，说明利差的周度方向变化中仍有大量接近白噪声的成分，这与 SHAP 分解中自回归项主导的发现互为印证——利差的可预测部分主要是其持续性部分。

（四）稳健性与机制讨论

综合上述三组证据，本文的结果链条完整且自洽：模型对比证实非线性机制的存在（H1），SHAP 分解揭示自回归与流动性双重主导的结构（H2），滚动预测证实样本外增量（H3）。就稳健性而言，四组利差在品种与期限维度上形成了天然的交叉验证：流动性主导的结构在中票上最强、商行债上次之；非线性优势在 3Y 上稳健，在 5Y 上则让位于线性趋势——两种模式均有清晰的经济机理支撑，而非孤立的统计巧合。就机制而言，本文的结果指向一个统一解释：中国信用利差的周度动态由“惯性+资金面”驱动，宏观基本面信息主要通过影响资金面预期间接传导，且传导在交易属性强的品种与短端期限上更为直接。

六、结论与政策建议

本文以 2016—2026 年中国信用债周度数据为样本，构建品种×期限四组信用利差，比较 OLS、随机森林与 XGBoost 三类模型的样本内解释力，运用 SHAP 方法分解特征贡献，并通过 expanding-window 滚动框架进行严格样本外检验。主要结论如下：

第一，中国信用利差的驱动机制存在显著非线性。3 年期利差上线性模型测试集 R^2 为负而树模型达到 0.36—0.69，表明简单线性投影无法刻画利差与驱动因素之间的真实关系，传统线性研究框架可能系统性低估了可解释部分。

第二，利差周度变动由自回归动量与流动性因素双重主导。SHAP 分解显示利差自身滞后项贡献了约四分之三的模型解释力，SHIBOR 3M 稳居第二，而 CPI、PPI、PMI 等宏观基本面变量贡献微弱，与 Collin-Dufresne 等（2001）的经典发现一致，亦呼应了中国市场流动性溢价主导定价的既有证据（纪志宏和曹媛媛，2017；Huang、Liu 和 Shi，2023）。

第三，机器学习模型具备超越随机游走的样本外预测能力。四条利差的滚动预测 RMSE 改善 9%—25%，且该优势在品种与期限维度上稳健。

本文的政策与实务含义有三：其一，对投资者而言，信用利差的周度监测应重点关注资金面指标与利差自身动量，宏观数据的边际信息有限，据此构建的组合再平衡规则有望获得可观的效率改进；其二，对监管者而言，流动性因素对利差的支配性影响提示，货币市场波动向信用债市场的传导是金融稳定的重要渠道，监测交易属性强的品种（如中票）的资金面敏感度可作为系统

性风险的早期预警指标；其三，对方法论而言，非线性机器学习与 SHAP 可解释性的结合为固定收益研究提供了兼顾预测与解释的分析范式，本文的全部代码与数据获取流程已开源，可供后续研究直接复现与扩展。

本文的不足与展望包括：样本仅覆盖 AAA 评级，评级维度的异质性有待扩展；特征集以宏观与市场变量为主，债券发行层面的微观信息（评级迁移、一级发行利差等）可以进一步纳入；滚动预测的步进设定（4 周）较长，更高频的再平衡策略值得检验。后续研究可在上述方向深化。

参考文献

- [1] MERTON R C. On the pricing of corporate debt: the risk structure of interest rates[J]. *Journal of Finance*, 1974, 29(2): 449-470.
- [2] LONGSTAFF F A, SCHWARTZ E S. A simple approach to valuing risky fixed and floating rate debt[J]. *Journal of Finance*, 1995, 50(3): 789-819.
- [3] DUFFEE G R. The relation between treasury yields and corporate bond yield spreads[J]. *Journal of Finance*, 1998, 53(6): 2225-2241.
- [4] COLLIN-DUFRESNE P, GOLDSTEIN R S, MARTIN J S. The determinants of credit spread changes[J]. *Journal of Finance*, 2001, 56(6): 2177-2207.
- [5] ELTON E J, GRUBER M J, AGRAWAL D, et al. Explaining the rate spread on corporate bonds[J]. *Journal of Finance*, 2001, 56(1): 247-277.
- [6] HUANG J Z, HUANG M. How much of the corporate-treasury yield spread is due to credit risk?[J]. *Review of Asset Pricing Studies*, 2012, 2(2): 153-202.
- [7] GILCHRIST S, ZAKRAJŠEK E. Credit spreads and business cycle fluctuations[J]. *American Economic Review*, 2012, 102(4): 1692-1720.
- [8] HUANG J Z, LIU B, SHI Z. Determinants of short-term corporate yield spreads: evidence from the commercial paper market[J]. *Review of Finance*, 2023, 27(2): 539-579.
- [9] HUANG J Z, NOZAWA Y, SHI Z. The global credit spread puzzle[J]. *Journal of Finance*, 2025, 80(1): 101-162.
- [10] BREIMAN L. Random forests[J]. *Machine Learning*, 2001, 45(1): 5-32.
- [11] CHEN T, GUESTRIN C. XGBoost: a scalable tree boosting system[C]//*Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: ACM, 2016: 785-794.
- [12] LUNDBERG S M, LEE S I. A unified approach to interpreting model predictions[C]//*Advances in Neural Information Processing Systems 30*. Red Hook: Curran Associates, 2017: 4765-4774.
- [13] BIANCHI D, BÜCHNER M, TAMONI A. Bond risk premiums with machine learning[J]. *Review of Financial Studies*, 2021, 34(2): 1046-1089.
- [14] 张燃. 信用价差变化的决定因素——一个宏观视角[J]. *当代财经*, 2008(9): 62-67.
- [15] 戴国强, 孙新宝. 我国企业债券信用利差宏观决定因素研究[J]. *财经研究*, 2011, 37(12): 61-71.
- [16] 纪志宏, 曹媛媛. 信用风险溢价还是市场流动性溢价：基于中国信用债定价的实证研究[J]. *金融研究*, 2017(2): 1-10.
- [17] 赵静, 方兆本. 中国公司债信用利差决定因素——基于结构化理论的实证研究[J]. *经济管理*, 2011, 33(11): 138-146.
- [18] 周荣喜, 彭航, 李欣宇, 等. 基于 XGBoost 算法的信用债违约预测模型[J]. *债券*, 2019(10): 61-68.
- [19] 王宇. 我国企业债信用利差宏观影响因素实证检验[J]. *债券*, 2013(11): 38-43.

Nonlinear Mechanisms and Out-of-Sample Predictability of Credit Spreads in China: Evidence from Interpretable Machine Learning with XGBoost and SHAP

ABSTRACT: The driving mechanism of credit spreads is a central issue in fixed-income pricing and credit risk management. Using weekly Chinese credit bond data from 2016 to 2026, this paper constructs four spread series across

instruments and maturities, and compares OLS, random forest, and XGBoost with SHAP-based interpretation and a strict expanding-window out-of-sample evaluation. We find that: (1) linear models fail on 3-year spreads (negative out-of-sample R^2) while tree models achieve 0.36—0.69, indicating significant nonlinearity in spread dynamics; (2) SHAP decompositions show that autoregressive momentum and the SHIBOR liquidity factor dominate, while macro fundamentals contribute marginally, echoing Collin-Dufresne et al. (2001); (3) XGBoost forecasts outperform the random walk in out-of-sample RMSE by 9%—25% across all four spreads. The evidence offers new insights into credit spread pricing in China and a practical toolkit for fixed-income investment and risk management.

KEYWORDS: credit spread; XGBoost; SHAP interpretability; machine learning; out-of-sample prediction